



Universitat
Oberta
de Catalunya

Master Universitario en ciencia de datos

Práctica 2

Tipología y ciclo de vida de los datos

Alumno: Pablo Ibarlucea González y Oscar Javier Bachiller Sandoval

Índice

1. Descripción del dataset	1
2. Integración y selección	1
3. Limpieza de datos	1
4. Análisis de los datos	2
4.1. Segmentación Regional (Clustering)	2
4.2. Clasificación Supervisada	2
4.3. Contraste de Hipótesis	2
5. Representación de los resultados	3
6. Resolución del problema	4
7. Código	4
8. Video	4
9. Contribuciones	5
Bibliografía	5

1. Descripción del dataset

El conjunto de datos base para este estudio proviene de una extracción realizada mediante técnicas de *web scraping* sobre el portal del Registro Único Empresarial y Social (RUES) de Colombia [1]. La importancia de este dataset radica en su capacidad para ofrecer una radiografía actual del tejido empresarial formal en diversas regiones del país, permitiendo analizar patrones de constitución, formalización y supervivencia de las organizaciones.

El archivo original cuenta con 4377 registros y 17 columnas. Las variables capturadas incluyen identificadores únicos (NIT), ubicación geográfica (**Cámara de Comercio**), información temporal (**Fecha de Matrícula, Renovación, Cancelación**) y categorización jurídica (**Tipo de Sociedad, Tipo de Organización**).

El problema analítico que se pretende abordar consiste en determinar si existen factores estructurales, tanto geográficos como macroeconómicos, que condicionen la elección del tipo societario y la pervivencia de las empresas. Para responder a esto, se hace necesario enriquecer la información registral, que es de carácter administrativo, con datos del contexto económico.

2. Integración y selección

Para dotar de contexto explicativo a los registros administrativos, decidimos integrar datos macroeconómicos externos procedentes del Banco Mundial [2]. Esta decisión se justifica por la hipótesis de que las condiciones económicas del momento de fundación (año de matrícula) influyen en la estructura legal adoptada por la empresa.

El proceso de integración se realizó mediante un script en Python que consume directamente la API del Banco Mundial. Se seleccionaron cinco indicadores clave: crecimiento del PIB anual, inflación al consumidor, tasa de desempleo total, tasa de interés para préstamos y remesas como porcentaje del PIB. Estos datos, originalmente en formato «ancho» (años como columnas), fueron transformados mediante una operación de *pivot* para alinearlos con la estructura tabular requerida.

Se cruzó el año de la **Fecha de Matrícula** con los indicadores económicos para capturar el entorno de nacimiento de la empresa.

El resultado es un dataset enriquecido donde cada empresa no solo tiene sus atributos legales, sino también una «foto» económica de su nacimiento.

3. Limpieza de datos

La fase de limpieza fue crítica debido a la naturaleza heterogénea de los datos extraídos de la web. Se identificaron inconsistencias en los formatos de fecha y cadenas de texto no estandarizadas.

En primer lugar, las columnas temporales (**Fecha de Matrícula, Vigencia**, etc.) se convirtieron al formato *datetime*. Se observó que una proporción significativa de registros carecía de fechas válidas o presentaba el valor «Indefinido» en la vigencia; estos casos se gestionaron extrayendo únicamente el año para los cruces, imputando con cero o descartando registros cuando la fecha de matrícula era inexistente, ya que es una variable indispensable para la integración económica.

Respecto a las variables categóricas, se detectó un desbalanceo severo en la variable objetivo **Tipo de Sociedad**. La clase «Sociedad Comercial» representa cerca del 90% de los datos, mientras que categorías como «Economía solidaria» tenían una presencia casi anecdótica. Para los análisis supervisados y las pruebas de hipótesis, se aplicaron filtros para excluir clases con menos de dos instancias, evitando errores en la estratificación durante la división de conjuntos de entrenamiento y prueba. Asimismo, para la prueba Chi-cuadrado, se agruparon las regiones minoritarias bajo la etiqueta «Otras Regiones» y los tipos societarios poco frecuentes bajo «Otros Tipos», asegurando así la robustez estadística de los resultados.

4. Análisis de los datos

El análisis se estructuró en tres enfoques complementarios: segmentación no supervisada, clasificación supervisada y contraste de hipótesis.

4.1. Segmentación Regional (Clustering)

Se aplicó el algoritmo K-Means combinado con una reducción de dimensionalidad PCA (Análisis de Componentes Principales). El objetivo fue identificar agrupaciones naturales de empresas basadas en su ubicación y las condiciones económicas de su fundación. Se determinó un número óptimo de 4 clústeres.

Los resultados mostraron un **Cluster 3** predominante que agrupa a más del 70% de las empresas, definiendo un «perfil base» nacional. Sin embargo, se detectaron anomalías regionales: el **Cluster 2** tiene una presencia significativa en Antioquia (39%), sugiriendo un ecosistema empresarial distintivo, mientras que el **Cluster 0** destaca en regiones como Montería y Chocó. Las métricas de validación (Silhouette Score = 0.36, Calinski-Harabasz = 2302) indican una estructura con centros densos pero fronteras difusas.

4.2. Clasificación Supervisada

Se entrenó un modelo *Random Forest* para predecir el **Tipo de Sociedad**. A pesar de obtener una exactitud general del 63.82%, el análisis detallado reveló dificultades asociadas al desbalanceo de clases. El modelo logró un alto *recall* (90%) para la clase minoritaria «Sociedad Civil», pero con una precisión muy baja, generando numerosos falsos positivos.

El hallazgo más relevante de este modelo fue la importancia de las variables predictoras. La variable **Cámara de Comercio (Medellín)** y los indicadores económicos (**Inflación, PIB** al momento de matrícula) resultaron ser los predictores más influyentes, validando que el origen geográfico y el ciclo económico determinan la forma jurídica.

4.3. Contraste de Hipótesis

Finalmente, se aplicó una prueba Chi-cuadrado de Pearson para evaluar la independencia entre la región (**Cámara de Comercio**) y el **Tipo de Sociedad**. Se obtuvo un valor-p virtualmente nulo ($p < 0.05$), rechazando la hipótesis de independencia. El mapa de calor de residuos estandarizados confirmó desviaciones significativas: Montería mostró un exceso de entidades sin ánimo de lucro, mientras que Antioquia presentó una preferencia superior a la esperada por la sociedad civil y comercial.

5. Representación de los resultados

Las visualizaciones generadas permitieron interpretar la complejidad de los modelos.




Figura 1: Proyección en 2D de los clústeres empresariales identificados.

La proyección PCA evidenció cómo, aunque existe una gran masa central de empresas homogéneas, ciertos grupos se separan en función de la varianza explicada por las condiciones económicas y geográficas. Por otro lado, la matriz de confusión del modelo de clasificación ilustró visualmente el desafío del desbalanceo, mostrando una clara tendencia del modelo a favorecer la clase mayoritaria.




Figura 2: Variables más relevantes para la predicción del tipo de sociedad.

El gráfico de importancia de variables fue fundamental para confirmar que la inflación y el desempleo no son ruido, sino señales determinantes en la caracterización de las empresas.




Figura 3: Mapa de calor de residuos estandarizados (Prueba Chi-Cuadrado).

Finalmente, la visualización de los residuos estandarizados ofrece una interpretación espacial de la dependencia estadística detectada. A diferencia de un simple valor-p, este gráfico permite identificar las celdas específicas responsables de la asociación: los colores intensos señalan dónde la realidad se desvía drásticamente del modelo teórico de independencia, confirmando visualmente las singularidades del tejido empresarial en regiones como Montería (exceso de entidades sin ánimo de lucro) y Antioquia (preferencia por la sociedad civil).

6. Resolución del problema

El análisis realizado permite concluir que el tejido empresarial colombiano no es uniforme. La integración de datos macroeconómicos demostró ser una estrategia efectiva, ya que las variables derivadas del Banco Mundial figuraron entre los principales predictores del comportamiento societario.

Se responde afirmativamente al problema planteado: existen diferencias estructurales significativas dependientes de la región y del momento económico. Las políticas de fomento empresarial o formalización no deberían ser homogéneas, dado que regiones como Antioquia o Montería exhiben dinámicas de constitución legal que difieren estadísticamente del estándar nacional (representado por Bogotá y otras capitales). El modelo predictivo, aunque perfectible en términos de precisión para clases minoritarias, validó la capacidad de anticipar el perfil legal de una empresa basándose únicamente en su contexto espacio-temporal.

7. Código

Se ha realizado el análisis en un cuaderno de jupyter que se incluye completamente al final de la memoria.

8. Video

El enlace al video en el que se presenta la práctica:

9. Contribuciones

Contribuciones	Firma
Investigación previa	Pablo Ibarlucea González, Oscar Javier Bachiller Sandoval
Redacción de las respuestas	Pablo Ibarlucea González, Oscar Javier Bachiller Sandoval
Desarrollo del código	Pablo Ibarlucea González, Oscar Javier Bachiller Sandoval
Participación en el vídeo	Pablo Ibarlucea González, Oscar Javier Bachiller Sandoval

Tabla 1: Tabla de contribuciones

Bibliografía

- [1] Confecámaras, «Registro Único Empresarial y Social (RUES)». [En línea]. Disponible en: <https://www.rues.org.co/>
- [2] World Bank Group, «World Development Indicators: Colombia». [En línea]. Disponible en: <https://data.worldbank.org/country/colombia>

Análisis de datos RUES

En este notebook realizamos una limpieza y análisis de los datos obtenidos mediante [web-scraping](#).

```
In [1]: # Imports
import pandas as pd
import numpy as np
from IPython.display import display, HTML
import warnings
warnings.filterwarnings('ignore')
```

Carga del dataset original

```
In [2]: df = pd.read_csv('dataset/rues_20251109_042421.csv')
```

Análisis de la calidad de los datos

```
In [3]: # Resumen de columnas numéricas
display(df.describe().T)
# Resumen de columnas no numéricas
df.describe(exclude="number").T
```

	count	mean	std	min	25%	50%	75%	max
Número de Matrícula	4377.0	6.897020e+08	2.359404e+09	2.0	141816.0	17618504.0	38794512.0	9.000701e+09
Último año renovado	4377.0	1.708965e+03	7.196395e+02	0.0	1997.0	2010.0	2021.0	2.025000e+03

```
Out[3]:
```

	count	unique	top	freq
Identificación	4377	3695	SIN IDENTIFICACION	335
Estado de la matrícula	4377	3	Activa	4371
nombre	4377	4377	COMERCIALIZADORA LA LLAMA S A	1
Categoría de la Matrícula	4377	3	Sociedad ó persona jurídica principal ó esal	4362
Tipo de Sociedad	4377	5	Sociedad comercial	3918
Tipo Organización	4376	23	Sociedades por acciones simplificadas sas	1854
Cámara de Comercio	4377	55	Medellin para antioquia	2005
Fecha de Matrícula	4362	2862	1996/05/01	29
Fecha de Vigencia	4361	1946	Indefinido	2065
Fecha de Cancelación	1	1	2024/12/14	1
Fecha de renovación	3131	1964	2025/03/31	94
Fecha de Actualización	4011	736	2020/11/21	318
Motivo Cancelación	1904	1	NORMAL	1904
Emprendimiento Social	632	2	N	568
Extinción de Dominio	101	1	N	101

Resultados:

En vista a los resúmenes observamos que la mayoría de columnas del dataframe según lo hemos cargado son no numéricas, de hecho las dos variables numéricas encontradas son el número de matrícula y el año que no son realmente numéricas.

La mayoría de columnas tienen pocos valores directamente faltantes pero se observan valores que marcan columnas vacías o desconocidas:

- El mínimo del año es 0, marcaremos este dato como nulo
- En identificación el dato más frecuente es la cadena: "SIN IDENTIFICACION"
- En la Fecha de vigencia el dato más frecuente es la cadena "Indefinido", esto es posible que se de en otros campos de tipo fecha. Sin embargo en estos caso una acción especial no será necesaria: cuando convirtamos el valor a tipo fecha fallará la conversión y tendremos un valor nulo.
- La columna de fecha de cancelación solo tiene un registro no nulo, con lo que esta columna deberá ser completamente descartada.

Otra cosa que podemos observar es varias variables con un número de valores únicos bajo, estas columnas son las propiamente categóricas:

- Estado de la matrícula
- Tipo de sociedad
- Tipo Organización

- Cámara de Comercio
- Categoría de matrícula
- Motivo de cancelación.

Un par de variables son booleanas marcadas con 'N' o 'S' (0 nulos)

- Emprendimiento Social
- Extinción de Dominio

(Estas variables tiene alto número de nulos)

Limpieza de los datos originales

Variables categóricas

```
In [4]: # Convertir las variables categóricas al tipo adecuado
category_cols = ["Estado de la matrícula", "Tipo de Sociedad", "Tipo Organización", "Cámara de Comercio", "Categoría"]
df[category_cols] = df[category_cols].astype("category")
```

```
In [5]: for col in df.select_dtypes(include="category"):
        cats = df[col].cat.categories

        table = (
            pd.DataFrame({"Categoría": cats})
            .to_html(index=False, escape=False)
        )

        display(HTML(f"<h3>{col}</h3>{table}"))
```

Estado de la matrícula

Categoría
Activa
Activa, constitución por traslado
Cancelada

Categoría de la Matrícula

Categoría
Establecimiento de comercio
Persona natural
Sociedad ó persona jurídica principal ó esal

Tipo de Sociedad

Categoría
Economía solidaria
Entidad sin animo de lucro
No aplica
Sociedad civil
Sociedad comercial

Tipo Organización

Categoría
Asociaciones agropecuarias y campesinas nacionales y no nacionales
Asociaciones de padres de familia
Asociaciones, corporaciones, fundaciones e instituciones de utilidad común (gremiales, de beneficencia; profesionales, juveniles, sociales, democráticas y participativas, cívicas y comunitarias, de egresados, de rehabilitación social y ayuda a indigentes y clubes sociales).
Cooperativas, federaciones y confederaciones, instituciones auxiliares de la economía solidaria y precooperativas.
Corporaciones
Corporaciones, asociaciones y fundaciones creadas para adelantar actividades en comunidades indígenas.
Empresas asociativas de trabajo
Empresas unipersonales
Entidades científicas, tecnológicas, culturales, e investigativas
Entidades de naturaleza cooperativa
Establecimientos de comercio
Fondo de empleados
Fundaciones
Las demás organizaciones civiles, corporaciones, fundaciones
Otras sociedades
Persona natural
Sociedad anonima
Sociedad colectiva
Sociedad en comandita por acciones
Sociedad en comandita simple
Sociedad extranjera
Sociedad limitada
Sociedades por acciones simplificadas sas

Cámara de Comercio

Categoría
Aburra sur
Aguachica
Amazonas
Arauca
Armenia
Barrancabermeja
Barranquilla
Bogota
Bucaramanga
Buenaventura
Buga
Cali
Cartagena
Cartago
Casanare
Cauca
Chocó
Cucuta
Dosquebradas
Duitama
Facatativa
Florencia para el caqueta
Girardot
Honda
Huila
Ibague
Ipiales
La guajira
Magangue
Magdalena medio
Manizales
Medellin para antioquia
Monteria
Ocana
Oriente antioqueno
Palmira
Pamplona
Pasto
Pereira
Piedemonte araucano
Putumayo
San andres
San jose
Santa marta para el magdalena
Santa rosa de cabal
Sevilla
Sincelejo
Sogamoso
Sur y oriente del tolima
Tulua
Tumaco
Tunja

Categoría
Uraba
Valledupar
Villavicencio

Variables de tipo fecha

```
In [6]: date_cols = ["Fecha de Matrícula", "Fecha de Vigencia", "Fecha de renovación", "Fecha de Actualización"]
df[date_cols] = df[date_cols].apply(pd.to_datetime, format="%Y/%m/%d", errors="coerce")
df
```

Out[6]:

	Identificación	Número de Matrícula	Estado de la matrícula	nombre	Categoría de la Matrícula	Tipo de Sociedad	Tipo Organización	Cámara de Comercio	Fecha de Matrícula	Fecha de Vigencia	C
0	NIT 800137336 - 0	15941604	Activa	COMERCIALIZADORA LA LLAMA S A	Sociedad ó persona jurídica principal ó esal	Sociedad comercial	Sociedad anonima	Medellin para antioquia	1991-07-01	2041-02-13	
1	NIT 800136312 - 0	15941804	Activa	VELPASS S A	Sociedad ó persona jurídica principal ó esal	Sociedad comercial	Sociedad anonima	Medellin para antioquia	1991-07-01	2021-06-26	
2	NIT 800135479 - 6	15942104	Activa	DILADA S A "EN LIQUIDACION"	Sociedad ó persona jurídica principal ó esal	Sociedad comercial	Sociedad anonima	Medellin para antioquia	1991-07-01	2041-07-15	
3	NIT 800137202 - 2	15968204	Activa	AIRE ACONDICIONADO Y REFRIGERACION DE COLOMBIA...	Sociedad ó persona jurídica principal ó esal	Sociedad comercial	Sociedad anonima	Medellin para antioquia	1991-07-01	2041-06-14	
4	NIT 800137801 - 3	15997912	Activa	CASMAR DE COLOMBIA S. A. S.	Sociedad ó persona jurídica principal ó esal	Sociedad comercial	Sociedades por acciones simplificadas	Medellin para antioquia	1991-08-01	NaT	
...	...	...	...	...	...	...	...	...	...	...	
4372	NIT 901285458 - 0	3114804	Activa	EL CONTACTO ELECTRONICO IND COL S.A.S	Sociedad ó persona jurídica principal ó esal	Sociedad comercial	Sociedades por acciones simplificadas	Bogota	2019-05-20	NaT	
4373	NIT 901231306 - 8	3037580	Activa	GENESIS CORPORATION IND JANIMAN GMBH S.A.S	Sociedad ó persona jurídica principal ó esal	Sociedad comercial	Sociedades por acciones simplificadas	Bogota	2018-11-16	2028-11-15	
4374	NIT 901615150 - 5	844753	Activa	PROCESOS INDUSTRIALES BC S.A.S. Sigla PROC IND...	Sociedad ó persona jurídica principal ó esal	Sociedad comercial	Sociedades por acciones simplificadas	Barranquilla	2022-07-21	NaT	
4375	NIT 900834734 - 1	611251	Activa	ESPECIALISTAS EN MANTENIMIENTO Y SOLUCIONES IN...	Sociedad ó persona jurídica principal ó esal	Sociedad comercial	Sociedades por acciones simplificadas	Barranquilla	2014-11-24	NaT	
4376	NIT 800149493 - 0	16373403	Activa	GRUPO INDUSTRIAL Y COMERCIAL CONSOLIDADO LIMITADA	Sociedad ó persona jurídica principal ó esal	Sociedad comercial	Sociedad limitada	Medellin para antioquia	1993-10-01	2011-12-05	

4377 rows x 17 columns

Variables booleanas

```
In [7]: bool_cols = ["Emprendimiento Social", "Extinción de Dominio"]
df[bool_cols] = (
    df[bool_cols]
    .apply(lambda s: s.map({"S": True, "N": False}))
    .astype("boolean")
)
```

Otros valores nulos

```
In [8]: df['Último año renovado'] = df['Último año renovado'].replace(0, pd.NA)
```

Columnas inválidas

Descartaremos para el análisis 'Fecha de cancelación' Por el elevado número de nulos. Además descartaremos identificación y número de matrícula por ser columnas identificativas y no características utilizable por un modelo posterior.

```
In [9]: df = df.drop(columns = ["Fecha de Cancelación", "Número de Matrícula", "Identificación"])
```

Integración de otros datos

Los datos obtenidos mediante web-scraping no tienen características numéricas que podamos utilizar para el posterior análisis.

Por eso es necesario que recuperemos datos de otras fuentes y los crucemos.

Integración de Contexto Macroeconómico

Se enriquecerá el dataset cruzando el año de matrícula con datos del Banco Mundial para capturar las condiciones económicas bajo las cuales se constituyó cada empresa. Los indicadores seleccionados son:

- **PIB_Crecimiento** : Crecimiento anual del PIB (%).
- **Inflacion** : Inflación anual basada en el IPC (%).
- **Desempleo** : Tasa de desempleo total (% de la fuerza laboral).
- **Tasa Interes** : Tasa de interés activa para préstamos bancarios.
- **Remesas_PIB** : Remesas personales recibidas (% del PIB).

```
In [10]: import requests
import zipfile
import io

url = "https://api.worldbank.org/v2/en/country/COL?downloadformat=csv"
response = requests.get(url)

with zipfile.ZipFile(io.BytesIO(response.content)) as z:
    file_name = [f for f in z.namelist() if f.startswith('API_COL') and f.endswith('.csv')][0]
    with z.open(file_name) as f:
        wb_source = pd.read_csv(f, skiprows=4)

# Añadir estos indicadores del World Bank como variables numéricas
target_indicators = {
    'NY.GDP.MKTP.KD.ZG': 'PIB_Crecimiento',
    'FP.CPI.TOTL.ZG': 'Inflacion',
    'SL.UEM.TOTL.ZS': 'Desempleo',
    'FR.INR.LEND': 'Tasa_Interes',
    'BX.TRF.PWKR.DT.GD.ZS': 'Remesas_PIB'
}

wb_clean = wb_source[wb_source['Indicator Code'].isin(target_indicators.keys())].copy()
wb_clean['Indicador'] = wb_clean['Indicator Code'].map(target_indicators)
wb_clean = wb_clean.drop(columns=['Country Name', 'Country Code', 'Indicator Name', 'Indicator Code', 'Unnamed: 68'])
wb_melted = wb_clean.melt(id_vars=['Indicador'], var_name='Year', value_name='Valor')
wb_melted['Year'] = pd.to_numeric(wb_melted['Year'], errors='coerce')
wb_pivot = wb_melted.dropna(subset=['Year']).pivot(index='Year', columns='Indicador', values='Valor').reset_index()
wb_pivot['Year'] = wb_pivot['Year'].astype(int)

# Integrar los indicadores tanto para el año de matricula
df['Year_Matricula'] = df['Fecha de Matrícula'].dt.year.fillna(0).astype(int)

wb_matricula = wb_pivot.add_suffix('_Matricula').rename(columns={'Year_Matricula': 'Year_Matricula'})

df = df.merge(wb_matricula, on='Year_Matricula', how='left')
```

Análisis de datos

Modelo no supervisado

Modelo de Segmentación Regional (Clustering)

En este apartado se implementa un algoritmo de aprendizaje no supervisado K-Means para identificar clústeres de empresas. El objetivo es encontrar patrones latentes que correlacionen la ubicación geográfica (Cámara de Comercio) y el tipo societario con el contexto económico de su fundación. Se utiliza una reducción de dimensionalidad con PCA (Análisis de Componentes Principales) dentro del pipeline para mejorar la separabilidad de los grupos y facilitar la visualización.

```
In [11]: from sklearn.cluster import KMeans
from sklearn.preprocessing import StandardScaler, OneHotEncoder
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.decomposition import PCA
```

```

# Selección de Features
cat_features = ['Tipo de Sociedad', 'Categoria de la Matrícula']
num_features = ['PIB_Crecimiento_Matricula', 'Inflacion_Matricula', 'Desempleo_Matricula']

# Limpieza rápida para el modelo
df_model = df[cat_features + num_features + ['Cámara de Comercio']].dropna().copy()

# StandardScaler para numéricos (K-Means es sensible a la escala)
# OneHotEncoder para categóricos
preprocessor = ColumnTransformer(
    transformers=[
        ('num', StandardScaler(), num_features),
        ('cat', OneHotEncoder(handle_unknown='ignore', sparse_output=False), cat_features)
    ])

# Incluimos PCA para reducir ruido y dimensionalidad antes de agrupar
n_clusters = 4
pipeline = Pipeline([
    ('preprocessor', preprocessor),
    ('pca', PCA(n_components=2)), # Reducimos a 2 componentes principales para visualizar
    ('kmeans', KMeans(n_clusters=n_clusters, random_state=44, n_init=10))
])

pipeline.fit(df_model)
df_model['Cluster'] = pipeline.named_steps['kmeans'].labels_
df_model['PCA_1'] = pipeline.named_steps['pca'].transform(pipeline.named_steps['preprocessor'].transform(df_model))[:
df_model['PCA_2'] = pipeline.named_steps['pca'].transform(pipeline.named_steps['preprocessor'].transform(df_model))[:

```

```

In [12]: import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.metrics import silhouette_score, calinski_harabasz_score

# Métricas para juzgar la bondad del clustering
X_processed = pipeline.named_steps['preprocessor'].transform(df_model)
sil_score = silhouette_score(X_processed, df_model['Cluster'])
ch_score = calinski_harabasz_score(X_processed, df_model['Cluster'])

metrics_df = pd.DataFrame({
    'Métrica': ['Silhouette Score', 'Calinski-Harabasz Score', 'Inercia (WCSS)'],
    'Valor': [f'{sil_score:.4f}', f'{ch_score:.2f}', f'{pipeline.named_steps["kmeans"].inertia_:.2f}'],
    'Interpretación': [
        'Separación (cercano a 1 es mejor)',
        'Densidad (más alto es mejor)',
        'Cohesión interna (menor es mejor)'
    ]
})

# Visualizaciones
fig, axes = plt.subplots(1, 2, figsize=(18, 6))

# Distribución Espacial de Clústeres (PCA)
sns.scatterplot(
    data=df_model, x='PCA_1', y='PCA_2',
    hue='Cluster', palette='viridis', style='Tipo de Sociedad',
    alpha=0.7, ax=axes[0]
)
axes[0].set_title('Mapa de Segmentación (Proyección PCA)')
axes[0].set_xlabel('Componente Principal 1 (Varianza Económica/Geo)')
axes[0].set_ylabel('Componente Principal 2')



# Filtramos las top 10 cámaras para que el gráfico sea legible
top_camaras = df_model['Cámara de Comercio'].value_counts().nlargest(10).index
heatmap_data = pd.crosstab(df_model[df_model['Cámara de Comercio'].isin(top_camaras)]['Cámara de Comercio'],
                           df_model['Cluster'], normalize='index')

sns.heatmap(heatmap_data, annot=True, fmt=".1%", cmap="YlGnBu", ax=axes[1])
axes[1].set_title('Distribución de Clústeres por Cámara de Comercio (Región)')
axes[1].set_ylabel('')

plt.tight_layout()
plt.show()

# Mostrar tabla de métricas
display(metrics_df)

```



	Métrica	Valor	Interpretación
0	Silhouette Score	0.3648	Separación (cercano a 1 es mejor)
1	Calinski-Harabasz Score	2302.82	Densidad (más alto es mejor)
2	Inercia (WCSS)	1877.87	Cohesión interna (menor es mejor)

Conclusiones del Modelo de Segmentación Regional

El análisis de segmentación revela la existencia de un perfil empresarial hegemónico, identificado en el Cluster 3, que define el comportamiento estándar del emprendimiento colombiano. Este grupo domina transversalmente la geografía nacional, concentrando más del 70% de los registros en ciudades principales como Bogotá o Pereira, e incluso superando el 84% en La Guajira, lo que sugiere una homogeneidad notable en las características de constitución y contexto económico base de la mayoría de las empresas, independientemente de su ubicación.

Sin embargo, surgen divergencias regionales significativas que rompen esta uniformidad. Medellín para Antioquia presenta una anomalía clara donde el Cluster 2 captura el 39% de los datos, evidenciando un tejido empresarial forjado bajo condiciones económicas o estructuras societarias distintivas que no se replican en el resto del país. Paralelamente, regiones como Montería y Chocó muestran una predilección por el Cluster 0, lo que podría señalar una adaptación empresarial específica a economías con desafíos estructurales propios, diferenciándose del núcleo de las grandes capitales.

Desde una perspectiva técnica, las métricas de evaluación validan la consistencia de estos hallazgos dentro de la complejidad inherente a los datos socioeconómicos. Aunque el Silhouette Score de 0.36 refleja una superposición natural entre los grupos debido a la ausencia de fronteras rígidas en este tipo de fenómenos, el elevado índice Calinski-Harabasz de 2302.82 confirma que los clústeres poseen centros densamente definidos, otorgando solidez estadística a la segmentación geográfica identificada.

Modelo de Clasificación: Predicción de Tipo de Sociedad por Región

Este módulo se enfoca en un problema de clasificación: predecir el **Tipo de Sociedad** más probable para una empresa, dada su **Cámara de Comercio** (proxy de región) y el contexto macroeconómico de su fundación. Para ello, se entrena un modelo de **Random Forest Classifier**, que es robusto ante relaciones no lineales y permite evaluar la importancia de las variables predictoras.

```
In [13]: from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score, classification_report, confusion_matrix

target_col = "Tipo de Sociedad"
# Las mismas numericas que usamos para clustering
cat_features = ["Cámara de Comercio", "Categoría de la Matrícula"]
predictive_features = cat_features + num_features

cols_for_classification = predictive_features + [target_col]
df_classification = df[cols_for_classification].dropna().copy()

# Filtramos clases con menos de 2 registros para evitar errores en la estratificación
v_counts = df_classification[target_col].value_counts()
classes_to_keep = v_counts[v_counts >= 2].index
df_classification = df_classification[df_classification[target_col].isin(classes_to_keep)].copy()

# Separar variable objetivo y predictores
X = df_classification[predictive_features]
y = df_classification[target_col]

# Codificación de variables categóricas necesarias para Random Forest
# One-Hot Encoding para Cámara de Comercio y Tipo de Sociedad (si no es target)
# El target 'Tipo de Sociedad' se manejará automáticamente por los clasificadores
ct_clf = ColumnTransformer(
    transformers=[
        ("num", StandardScaler(), num_features),
        (
            "cat",
```

```

        OneHotEncoder(handle_unknown="ignore", sparse_output=False),
        cat_features,
    ),
    ],
    remainder="passthrough",
)

X_processed = ct_clf.fit_transform(X)

# Convertir el resultado del ColumnTransformer a DataFrame para que el Random Forest lo maneje bien
# Obtener nombres de columnas después del OneHotEncoding
cat_names = ct_clf.named_transformers_["cat"].get_feature_names_out()
all_feature_names = num_features + list(cat_names)
X_processed_df = pd.DataFrame(X_processed, columns=all_feature_names)

# Dividir datos en entrenamiento y prueba
X_train, X_test, y_train, y_test = train_test_split(
    X_processed_df, y, test_size=0.25, random_state=42, stratify=y
)

# Definición y entrenamiento del modelo random forest
model_rf = RandomForestClassifier(
    n_estimators=200, random_state=42, class_weight="balanced", n_jobs=-1
)
model_rf.fit(X_train, y_train)

y_pred = model_rf.predict(X_test)

```

```

In [14]: # Métricas
accuracy = accuracy_score(y_test, y_pred)
class_report = classification_report(y_test, y_pred, zero_division=0)
conf_matrix = confusion_matrix(y_test, y_pred)

print(f"Accuracy General: {accuracy:.4f}\n")
print("Reporte de Clasificación:\n", class_report)

# Visualizaciones
fig, axes = plt.subplots(1, 2, figsize=(18, 7))

# Matriz de Confusión
sns.heatmap(
    conf_matrix,
    annot=True,
    fmt="d",
    cmap="Blues",
    ax=axes[0],
    xticklabels=model_rf.classes_,
    yticklabels=model_rf.classes_,
)
axes[0].set_title("Matriz de Confusión")
axes[0].set_xlabel("Predicción")
axes[0].set_ylabel("Real")

# Importancia de las Variables
feature_importances = pd.Series(model_rf.feature_importances_, index=X_train.columns)
top_features = feature_importances.nlargest(10).sort_values(ascending=True)

top_features.plot(
    kind="barh", ax=axes[1], color=sns.color_palette("viridis", len(top_features))
)
axes[1].set_title("Top 10 Variables Importantes para la Predicción")
axes[1].set_xlabel("Importancia")
axes[1].set_ylabel("")


plt.tight_layout()
plt.show()

```

Accuracy General: 0.6382

Reporte de Clasificación:

	precision	recall	f1-score	support
Economía solidaria	0.00	0.00	0.00	1
Entidad sin ánimo de lucro	0.39	0.68	0.49	84
Sociedad civil	0.07	0.90	0.13	21
Sociedad comercial	0.95	0.63	0.76	936
accuracy			0.64	1042
macro avg	0.35	0.55	0.34	1042
weighted avg	0.89	0.64	0.72	1042



Conclusiones del Modelo de Clasificación

El desempeño del modelo Random Forest evidencia un desafío crítico derivado del severo desbalanceo en los datos, donde la categoría "Sociedad Comercial" domina masivamente la muestra abarcando cerca del 90% de los registros. Si bien la exactitud general del 63.82% parece aceptable, el ajuste de pesos para equilibrar las clases provocó una distorsión significativa en las predicciones de las categorías minoritarias. Esto es particularmente notable en la "Sociedad Civil", donde el modelo logró identificar el 90% de los casos reales (recall) pero a costa de una precisión extrema del 7%, generando un gran número de falsos positivos al clasificar erróneamente muchas sociedades comerciales como civiles.

Pese a las dificultades de distinción entre clases, el análisis de importancia de variables valida rotundamente la hipótesis de integración de datos. La procedencia geográfica, específicamente de Medellín, resultó ser el predictor más potente, corroborando la singularidad del ecosistema empresarial antioqueño observada en la fase no supervisada. Además, el hecho de que la inflación, el crecimiento del PIB y el desempleo del año de matrícula sean las variables subsiguientes más influyentes confirma que las condiciones macroeconómicas del momento fundacional son determinantes en la elección de la estructura legal de una organización.

Para iteraciones futuras que busquen perfeccionar este enfoque, sería recomendable simplificar la variable objetivo mediante la agrupación de las categorías minoritarias, como entidades sin ánimo de lucro y sociedades civiles, bajo una etiqueta común de "No Comercial". Esta estrategia reduciría el ruido estadístico actual y permitiría al algoritmo construir fronteras de decisión más robustas, mitigando la confusión existente entre las clases con poca representación y la clase dominante.

Contraste Geográfico de Tipos de Sociedad (Chi-Cuadrado)

Para validar estadísticamente si la ubicación geográfica influye de manera determinante en la elección jurídica de la empresa, se aplica una prueba de independencia Chi-Cuadrado de Pearson. Este análisis busca refutar la hipótesis nula de que el **Tipo de Sociedad** y la **Cámara de Comercio** (región) son variables independientes. Dado el desbalanceo detectado previamente en los datos, el script incluye un paso de preprocesamiento para agrupar categorías minoritarias, asegurando que se cumplan las condiciones teóricas de la prueba (frecuencias esperadas mayores a 5 en la mayoría de las celdas), garantizando así la fiabilidad del valor-p resultante.

```
In [15]: import scipy.stats as stats

df_chi = df[['Cámara de Comercio', 'Tipo de Sociedad']].dropna().copy()

# Para cumplir la condición de Chi-Cuadrado (frecuencias esperadas > 5),
# agrupamos las cámaras con pocas empresas y los tipos de sociedad minoritarios.

# Agrupar Cámaras: Top 10 + 'Otras'
top_camaras = df_chi['Cámara de Comercio'].value_counts().nlargest(10).index
df_chi['Region_Agrupada'] = df_chi['Cámara de Comercio'].apply(lambda x: x if x in top_camaras else 'Otras Regiones')

# Agrupar Tipos de Sociedad: Mantener los que tengan > 1% de datos, resto a 'Otros'
threshold = len(df_chi) * 0.01
soc_counts = df_chi['Tipo de Sociedad'].value_counts()
valid_socs = soc_counts[soc_counts > threshold].index
df_chi['Sociedad_Agrupada'] = df_chi['Tipo de Sociedad'].apply(lambda x: x if x in valid_socs else 'Otros Tipos')

contingency_table = pd.crosstab(df_chi['Region_Agrupada'], df_chi['Sociedad_Agrupada'])

# Ejecución de la prueba
chi2_stat, p_val, dof, expected = stats.chi2_contingency(contingency_table)

# Cálculo del tamaño del Efecto (V de Cramér)
n = contingency_table.sum().sum()
min_dim = min(contingency_table.shape) - 1
cramers_v = np.sqrt(chi2_stat / (n * min_dim))


In [16]: # Visualización
# Heatmap de Residuos Estandarizados (Muestra dónde están las desviaciones significativas)
# Residuo > 2 o < -2 indica desviación significativa
```

```
residuals = (contingency_table - expected) / np.sqrt(expected)

plt.figure(figsize=(12, 6))
sns.heatmap(residuals, annot=True, fmt=".1f", cmap="RdBu_r", center=0, linewidths=.5)
plt.title('Mapa de Calor de Residuos Estandarizados\n(Azul = Más frecuencia de la esperada | Rojo = Menos)')
plt.ylabel('Región')
plt.xlabel('Tipo de Sociedad')
plt.show()

results_data = {
    'Estadístico Chi2': [f"{chi2_stat:.2f}"],
    'P-Valor': [f"{p_val:.4e}"], # Notación científica si es muy bajo
    'Grados de Libertad': [dof],
    'V de Cramér': [f"{cramers_v:.4f}"],
    'Interpretación': ['Asociación Significativa' if p_val < 0.05 else 'Independientes']
}

display(pd.DataFrame(results_data))
```



Conclusiones del Contraste Geográfico

La prueba estadística es concluyente: con un P-Valor virtualmente nulo (8.27×10^{-163}) y una V de Cramér de 0.2568, el análisis rechaza categóricamente la hipótesis de independencia, confirmando una asociación moderada pero estructural entre la ubicación geográfica y la forma jurídica adoptada. Esto demuestra que la elección del tipo societario no es un fenómeno aleatorio ni uniforme en el territorio nacional, sino que está fuertemente condicionado por dinámicas locales específicas que alteran la distribución esperada.

El mapa de calor de residuos estandarizados identifica con precisión dónde residen estas discrepancias. Montería emerge como el caso más anómalo del conjunto de datos, exhibiendo una sobrepoblación masiva de "Entidades sin ánimo de lucro" con un residuo extremo de +22.1, lo que sugiere un ecosistema volcado hacia este tipo de organizaciones en detrimento de las comerciales. En contraposición, Medellín para Antioquia muestra un comportamiento inverso y único: presenta un déficit significativo de entidades sin ánimo de lucro (residuo -12.4) compensado por una preferencia inusualmente alta por la "Sociedad Civil" (residuo +8.1), validando matemáticamente la singularidad del tejido empresarial antioqueño observada en los modelos previos.